

例题

假设有 4 个样本点，如下划分成 2 个簇：

- 簇 1： (0, 0), (0, 2)
- 簇 2： (10, 0), (10, 2)

运用上述两种簇划分，计算它们的 CH 指数。

解答步骤

1. 写出公式

- 簇内**凝聚程度** (cohesion)：

$$C_i = \sum_{x \in D_i} \|x - m_i\|^2$$

其中 m_i 是第 i 个簇的质心， D_i 是第 i 个簇的样本集合。

- 簇间**分离程度** (separation)：

$$S_i = \|m_i - m\|^2$$

其中 m 是全局质心。

- CH 指数定义为：

$$CH = \frac{\sum_{i=1}^K n_i S_i}{\sum_{i=1}^K C_i}$$

其中 n_i 是第 i 个簇的样本数， K 是簇的总数。

2. 计算各个质心

1. 簇 1 的质心

$$m_1 = \frac{(0, 0) + (0, 2)}{2} = (0, 1)$$

2. 簇 2 的质心

$$m_2 = \frac{(10, 0) + (10, 2)}{2} = (10, 1)$$

3. 全局质心

$$m = \frac{(0, 0) + (0, 2) + (10, 0) + (10, 2)}{4} = (5, 1)$$

3. 计算凝聚程度 C_i

- 簇 1：

$$C_1 = \|(0, 0) - (0, 1)\|^2 + \|(0, 2) - (0, 1)\|^2 = 1 + 1 = 2$$

- 簇 2：

$$C_2 = \|(10, 0) - (10, 1)\|^2 + \|(10, 2) - (10, 1)\|^2 = 1 + 1 = 2$$

4. 计算分离程度 S_i

- 簇 1：

$$S_1 = \|m_1 - m\|^2 = \|(0, 1) - (5, 1)\|^2 = 5^2 + 0^2 = 25$$

- 簇 2：

$$S_2 = \|m_2 - m\|^2 = \|(10, 1) - (5, 1)\|^2 = 5^2 + 0^2 = 25$$

5. 带入 CH 公式

- 每簇大小： $n_1 = 2, n_2 = 2$
- $\sum_i n_i S_i = 2 \times 25 + 2 \times 25 = 100$
- $\sum_i C_i = 2 + 2 = 4$

$$CH = \frac{100}{4} = 25$$

最终答案

$CH = 25$

– 值越大，表示簇内样本更“紧凑”，簇间更“分离”。